

Desafio 2: ganho calibrado faz a rede de 48 camadas treinar

Caio Couto · Victor Franco · MLP 256 × L, sem BatchNorm e sem residual, SGD lr 0,05 com momento 0,9, 3 épocas

COMO FIZEMOS

1. Ativação

$f(x) = 0,5 \cdot \text{LeakyReLU}(x; 0,2)$

Elemento a elemento e sem parâmetros. A inclinação negativa mantém gradiente em todas as unidades.

2. Escala dos pesos, calculada

$s^2 = 1 / (\text{fan_in} \cdot E[f(z)^2])$

$E[f^2]$ por Monte Carlo (10^6 amostras de $z \sim N(0,1)$), então a variância fica ≈ 1 em toda camada. Pesos **ortogonais** reescalados a s . Camada 1: $s^2 = 1/\text{fan_in}$. Logits: $s \times 0,1$. Viés 0.


3. O ganho 0,5 é o que destrava

No passo 0 a rede é idêntica (os pesos crescem 2× para compensar), mas a taxa de aprendizado efetiva das camadas ocultas cai para $\frac{1}{4}$. Com lr 0,05 e momento 0,9, esse passo menor evita a divergência.

4. Como escolhemos

20 candidatos (ativação × critério × pesos × ganho) numa triagem com o harness (25% dos dados, 1 época). Os 6 melhores foram para o modo completo: 3 épocas, 3 sementes.

RAIO-X EM L = 48 (MNIST, PASSO 0)



A baseline **apaga o sinal** (10^{-32}). ReLU + He preserva a variância, mas com gradientes $\sim 100\times$ maiores: o SGD passa do ponto e para na chance. A nossa tem **variância ≈ 1 e gradiente estável**.

RESULTADOS (MODO COMPLETO)

S = 114,0 de 125 possíveis
média 1,20 · mín. 1,01
9/9 tarefas acima da ref.

acurácia de teste	L = 4	L = 16	L = 48
MNIST	97,1% ref 96,7%	96,4% ref 95,6%	95,1% ref 11,3%
Fashion	87,3% ref 86,8%	87,0% ref 84,1%	81,0% ref 10,0%
CIFAR-10	48,8% ref 45,1%	48,1% ref 41,3%	38,4% ref 10,0%

ESCORE S POR CANDIDATO

LeakyReLU 0,2 · ganho 0,5		114,0
GELU · ganho 0,5		113,4
ReLU ortogonal · ganho 0,5		113,3
ReLU + He (referência)		100,0
tanh crítica · ganho 0,5		72,6
ReLU ortogonal · ganho 0,7		61,4
tanh + U(±0,05) (baseline)		0,0