GBC073 · DESAFIO 3

Otimizadores e agendas de taxa de aprendizado em DQN (Pong)

Testamos 5 otimizadores — SGD, SGD+Nesterov, Adam, AdamW e Muon — cada um com 4 agendas de η, treinando um DQN em Pong a partir de pixels.

1. Varredura exploratória

Orçamento curto (12k passos) para testar 5 η por otimizador e 4 agendas, descartando as combinações claramente ruins.

2. Confirmação

As 3 combinações mais promissoras, agora com 160.000 passos e 3 sementes cada — orçamento igual entre elas, para comparação justa.

3. Diagnóstico

Perda, norma do gradiente, norma dos parâmetros e razão de atualização, registrados a cada passo — inclusive uma execução propositalmente instável.

Ambiente: ALE/Pong-v5 (Gymnasium), CNN estilo Nature DQN, replay buffer + rede-alvo. Muon implementado do zero (ortogonalização via Newton-Schulz).

RESULTADO

A agenda de LR importou mais que o otimizador: quase +9 pontos sobre a baseline

Baseline

AdamW · agenda constante · η=3e-4

-20,8

média de 3 sementes — nível de jogo aleatório

Melhor combinação

AdamW+one_cycle e Adam+warmup_cosseno (η=3e-4) — empatados

≈ -11,9

+8,9 pontos vs. baseline, nas 3 sementes de cada

Muon

constante · η=0,02 · mesmo orçamento

-20,7

não decolou neste η/orçamento

O ganho veio da troca de agenda (constante → one_cycle/warmup_cosseno), não de qual otimizador entre Adam e AdamW: os dois empatam estatisticamente. O Muon, testado no mesmo orçamento (160k passos, η=0,02), não saiu do nível aleatório — pode precisar de mais passos ou outro η.

Orçamento reduzido e igual entre as comparações finais (160.000 passos); Muon testado com 1 semente no mesmo orçamento por restrição de tempo.

DIAGNÓSTICO

O que os sinais mostram quando o treino desanda

Execução instável (η=0,1, sem clipping)

1.261.601

perda no primeiro passo de otimização

815.709

norma do gradiente no mesmo passo

Execuções saudáveis (todas as outras)

≈ 0,01 – 0,06

perda, do início ao fim do treino

≈ 0,01 – 0,1

norma do gradiente, estável

Com η alto e sem clipping de gradiente, a perda e a norma do gradiente explodem em um único passo — por isso todas as execuções "saudáveis" deste trabalho usam clipping (norma máxima 10). Já na baseline (agenda constante), a norma dos parâmetros só diminui; nas combinações vencedoras, ela cresce e estabiliza — sinal de ajuste real aos dados, não apenas regularização.

painel.pdf traz os 4 sinais lado a lado para baseline, melhor configuração, melhor com Muon e a execução instável.